

Guía de Actividades Práctico-Experimentales Nro. 004

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	1
Resultado de aprendizaje de la unidad	Calcula probabilidades y momentos de variables aleatorias discretas, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	004
Título de la Práctica	Momentos Estadísticos: Esperanza Matemática, Varianza y Análisis de Tendencia Central con Python
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 005 de abril 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Calcular** teórica y computacionalmente la esperanza matemática ($E[X]$) y la varianza ($V[X]$) de variables aleatorias discretas y continuas utilizando la librería `scipy.stats` en Python.
- **Aplicar** el análisis de tendencia central y dispersión sobre el conjunto de datos (dataset) regional seleccionado para el Proyecto Integrador, facilitando el hito de la semana.
- **Validar** los conceptos adquiridos en la clase invertida de la semana 4 (variables aleatorias) integrándolos en la resolución de problemas (ABP).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).



unl

Universidad
Nacional
de Loja

- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Inicio:

Enfoque PID-2025: ABP y ABI. Duración: 120 min. Modalidad: grupal (2-3 estudiantes).

Desarrollo:

Enfoque PID-2025:

ABP (Aprendizaje Basado en Problemas): Los estudiantes resolverán el desafío de calcular y dar sentido a los momentos estadísticos de su propio dataset regional, enfrentándose a problemas reales de distribución de datos (sesgos, valores atípicos).

ABI (Aprendizaje Basado en Investigación): Búsqueda guiada en la documentación oficial de Scipy y Pandas para justificar la elección de funciones (ej. ddof=1 en varianza muestral).

Duración sugerida: 120 min. (presencial).

Modalidad: Grupos de trabajo (para el Proyecto Integrador) con ejecución técnica individual.

Procedimiento / Metodología

Tarea 1: Validación de Clase Invertida (Semana 4)

Dado el feriado del 01 de mayo, esta sección evalúa la participación en la clase invertida.

Abra el Jupyter Notebook generado en el trabajo autónomo de la Semana 4.

Asegúrese de que el bloque de código contenga su modificación personal (ej. simulación de la variable de Bernoulli).

Ejecute el script y presente visualmente al docente la PMF (Función de Masa de Probabilidad) generada para validar su puntaje de participación.

Script y presentación visual del código elegido por el grupo A:

```
import numpy as np

import pandas as pd

from scipy.stats import binom, norm

# Carga de datos real

df_regional = pd.read_csv('dataset_pandas_grupoA.csv', sep=';',
thousands='.', header=2)

df_regional.rename(columns={df_regional.columns[0]: 'Edad'},
inplace=True)

df_regional = df_regional[df_regional['Edad'] != 'Total']

# 1. Variable Aleatoria Discreta (Basada en la frecuencia de un
grupo)

# Ejemplo: Probabilidad de éxito p calculada como la proporción de
un rango específico

total_mujeres = df_regional['Mujer'].sum()

n_ensayos = 10

p_exito = df_regional.iloc[0]['Mujer'] / total_mujeres # Proporción
del primer rango

var_discreta = binom(n_ensayos, p_exito)

# Cálculo de Momentos Teóricos (Mean, Variance)

esperanza_d, varianza_d = var_discreta.stats(moments='mv')

print(f"---      Variable      Discreta      (Binomial      n={n_ensayos},
p={p_exito:.4f}) ---")

print(f"Esperanza E[X]: {esperanza_d:.2f}")
```



```
print(f"Varianza V[X]: {varianza_d:.2f}\n")

# 2. Variable Aleatoria Continua (Distribución Normal basada en tus
datos)

# Usamos la media y desviación real de tu columna 'Mujer'

mu = df_regional['Mujer'].mean()

sigma = df_regional['Mujer'].std()

var_continua = norm(loc=mu, scale=sigma)

esperanza_c, varianza_c = var_continua.stats(moments='mv')

print(f"---      Variable      Continua      (Normal      mu={mu:.2f},
sigma={sigma:.2f})  ---")

print(f"Esperanza E[X]: {esperanza_c:.2f}")

print(f"Varianza V[X]: {varianza_c:.2f}")
```

```
--- Variable Discreta (Binomial n=10, p=0.0090) ---
Esperanza E[X]: 0.09
Varianza V[X]: 0.09

--- Variable Continua (Normal mu=10190.62, sigma=9489.45) ---
Esperanza E[X]: 10190.62
Varianza V[X]: 90049650.25
```

```
import pandas as pd

import seaborn as sns

import matplotlib.pyplot as plt

import numpy as np

# Carga de datos (/content/dataset_pandas_grupoA.csv)

df_regional = pd.read_csv('dataset_pandas_grupoA.csv', sep=';',
thousands='.', header=2)

df_regional.rename(columns={df_regional.columns[0]: 'Edad'},
inplace=True)

df_regional = df_regional[df_regional['Edad'] != 'Total']
```

```
# SIMULACIÓN (A falta del dataset real en esta guía, usamos datos
simulados para ilustrar)

# (Se utilizan los datos cargados del CSV superior)

# Cálculo de Estadísticos usando Pandas

columna_obj = 'Mujer'

media_muestral = df_regional[columna_obj].mean()

varianza_muestral = df_regional[columna_obj].var(ddof=1) # ddof=1
para muestra insesgada

print(f"Análisis del Dataset Regional - Variable: {columna_obj}")
print(f"Media Muestral (Estimador de  $E[X]$ ): {media_muestral:.2f}")
print(f"Varianza Muestral (Estimador de  $V[X]$ ):
{varianza_muestral:.2f}")

# Visualización para el hito del proyecto

plt.figure(figsize=(12, 6))

sns.barplot(data=df_regional, x='Edad', y=columna_obj,
color='blue', alpha=0.7)


plt.axhline(media_muestral, color='red', linestyle='--',
label=f'Media: {media_muestral:.2f}')

plt.title('Distribución de Frecuencias y Tendencia Central')

plt.xticks(rotation=45)

plt.legend()

plt.show()
```



Tarea 2: Cálculo Teórico y Simulación de Esperanza Matemática ($E[X]$)

Recordemos que para una variable discreta, la esperanza se define como

$$E[X] = \sum x \cdot P(X = x), \quad \text{y para una continua como}$$

$$E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

1. Abra un nuevo Jupyter Notebook llamado **APE_005_Momentos.ipynb**.
2. Escriba y ejecute el siguiente script para calcular momentos usando la abstracción de `scipy.stats`.

```
import numpy as np

from scipy.stats import binom, norm

# 1. Variable Aleatoria Discreta (Distribución Binomial)
n_ensayos, p_exito = 10, 0.4

var_discreta = binom(n_ensayos, p_exito)

# Cálculo de Momentos Teóricos (Mean, Variance)
esperanza_d, varianza_d = var_discreta.stats(moments='mv')

print(f"--- Variable Discreta (Binomial n={n_ensayos}, p={p_exito}) ---")
```



```
print(f"Esperanza E[X]: {esperanza_d}")

print(f"Varianza V[X]: {varianza_d}\n")

# 2. Variable Aleatoria Continua (Distribución Normal)

mu, sigma = 50, 5 # Media y Desviación Estándar

var_continua = norm(loc=mu, scale=sigma)

esperanza_c, varianza_c = var_continua.stats(moments='mv')

print(f"--- Variable Continua (Normal mu={mu}, sigma={sigma}) ---")

print(f"Esperanza E[X]: {esperanza_c}")

print(f"Varianza V[X]: {varianza_c}")
```

Tarea 3: Hito del Proyecto - Análisis de Tendencia Central y Dispersión

Aplique los conceptos teóricos a su conjunto de datos regional.

Cargue su dataset regional utilizando pandas.

Identifique al menos dos variables cuantitativas clave para su estudio.

Desarrolle un script que calcule la media muestral () y la varianza muestral (). Utilice la formulación insesgada donde la suma de cuadrados se divide por .

```
import pandas as pd

import seaborn as sns

import matplotlib.pyplot as plt

# Carga de datos (Reemplace con la ruta de su dataset regional)

# df_regional = pd.read_csv('datos_loja.csv')

# SIMULACIÓN (A falta del dataset real en esta guía, usamos datos simulados para
ilustrar)

np.random.seed(42)

df_regional = pd.DataFrame({

    'Temperatura_Promedio': np.random.normal(loc=18.5, scale=2.1, size=300),

    'Precipitacion_mm': np.random.exponential(scale=15.0, size=300)

})

# Cálculo de Estadísticos usando Pandas

columna_obj = 'Temperatura_Promedio'

media_muestral = df_regional[columna_obj].mean()

varianza_muestral = df_regional[columna_obj].var(ddof=1) # ddof=1 para muestra
insesgada
```



unl

Universidad
Nacional
de Loja

```
print(f"Análisis del Dataset Regional - Variable: {columna_obj}")

print(f"Media Muestral (Estimador de E[X]): {media_muestral:.2f}")

print(f"Varianza Muestral (Estimador de V[X]): {varianza_muestral:.2f}")

# Visualización para el hito del proyecto

plt.figure(figsize=(8, 5))

sns.histplot(df_regional[columna_obj], kde=True, color='blue', stat='density')

plt.axvline(media_muestral, color='red', linestyle='--', label=f'Media: {media_muestral:.2f}')

plt.title('Distribución de Frecuencias y Tendencia Central')

plt.legend()

plt.show()
```

Tarea 4: ABI - Documentación y Discusión Grupal

Investigue en la documentación de Pandas qué significa el parámetro `ddof=1` utilizado en la función `.var()`. Redacte un breve párrafo (en formato Markdown dentro de su Jupyter Notebook) justificando estadísticamente por qué se utiliza en lugar de al trabajar con una muestra de su dataset regional, utilizando los conceptos de estimador insesgado. Utilizar la librería `itertools` de Python para generar espacios muestrales de experimentos aleatorios.

Metodología activa empleada: ABP (Aprendizaje Basado en Problemas) – según enfoque PID-2025.

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (`itertools`).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- ¿Cuál es la diferencia matemática y conceptual entre la esperanza matemática teórica calculada a partir de un modelo de probabilidad (ej. `binom.stats()`) y la media muestral calculada de un `DataFrame` de pandas?

Esperanza Matemática ($E[X]$)

Es un concepto **teórico** y **a priori**. Representa lo que "esperas" que ocurra en promedio si pudieras repetir un experimento infinitas veces bajo un modelo matemático perfecto.

- **Origen:** Proviene de una función de probabilidad (como la Binomial, Normal, etc.).
- **Cálculo:** No utiliza datos reales, sino parámetros (π , n , u , o).
 - Ejemplo Binomial: $E[X] = n \cdot p$

Naturaleza: Es un valor **fijo y determinista**. Si los parámetros no cambian, la esperanza no cambia.

- **En Python:** `binom.stats(n, p, moments='m')` calcula este valor exacto usando la fórmula teórica.

Media Muestral ($\bar{X}$)

Es un concepto **empírico** y **a posteriori**. Es el promedio aritmético de los datos que realmente lograste recolectar.

Origen: Proviene de una muestra finita de datos observados.

Cálculo: La suma de todos los valores observados dividida por el número total de observaciones (n):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Naturaleza: Es una **variable aleatoria**. Si tomas una muestra hoy y otra mañana, la media muestral de Pandas (`df['columna'].mean()`) probablemente será distinta en cada ocasión debido al error de muestreo.

Comparativa Directa

Característica	Esperanza Matemática (Teórica)	Media Muestral (Empírica)
Símbolo	μ o $E[X]$	$\bar{x}$
Dependencia	Del modelo y sus parámetros	De los datos recolectados
Estabilidad	Constante	Varía según la muestra
Herramienta	<code>scipy.stats</code> (ej. <code>binom.stats</code>)	<code>pandas</code> (ej. <code>df.mean()</code>)
Contexto	Población / Ideal	Muestra / Realidad

La Ley de los Grandes Números

La relación entre ambas es fundamental en estadística. Según la **Ley de los Grandes Números**, a medida que el tamaño de tu muestra en el DataFrame de Pandas aumenta ($n \rightarrow \infty$), la **media muestral** se aproxima cada vez más a la **esperanza matemática** teórica.

- **Demuestra teóricamente, utilizando las propiedades de la esperanza, por qué la varianza se puede reescribir como**
$$V[X] = E[X^2] - (E[X])^2.$$

1. Definición de Varianza

La varianza de una variable aleatoria X se define como:

$$V(X) = E[(X - E(X))^2]$$

Esta expresión mide qué tan dispersos están los valores de X respecto a su media.

2. Desarrollo de la expresión

Expandimos el cuadrado:

$$(X - E(X))^2 = X^2 - 2X \cdot E(X) + (E(X))^2$$

Ahora aplicamos la esperanza a cada término:

$$E[(X - E(X))^2] = E[X^2 - 2X \cdot E(X) + (E(X))^2]$$

Usamos propiedades de la esperanza:

- Linealidad: $E[aX + b] = aE[X] + b$

- Constantes salen de la esperanza

Entonces:

$$E[X^2 - 2X \cdot E(X) + (E(X))^2] = E[X^2] - 2E(X)E[X] + (E(X))^2$$

Como $E[X]$ es constante:

$$= E[X^2] - 2(E[X])^2 + (E[X])^2$$

3. Simplificación

Simplificando términos:

$$= E[X^2] - (E[X])^2$$

4. Conclusión

Por lo tanto, se demuestra que:

$$V(X) = E[X^2] - (E[X])^2$$

Esta forma es muy útil porque permite calcular la varianza usando solo momentos de la variable (esperanza y esperanza del cuadrado), sin necesidad de trabajar directamente con la definición original.

- **Si la varianza calculada en su variable regional es inusualmente alta, ¿qué implicaciones prácticas tiene esto sobre la confiabilidad de la media como predictor del comportamiento de esos datos en la región de Loja?**

La media pierde representatividad por lo que el promedio ya no describe bien a la población, porque hay grandes diferencias entre edades. La media se vuelve poco confiable como predictor y no se puede asumir que la mayoría de personas está cerca de ese valor promedio. Puede haber grupos muy distintos coexistiendo, por ejemplo, muchos jóvenes y muchos adultos mayores, lo que distorsiona el promedio. Si la varianza es alta, la media no es un buen predictor del comportamiento de los datos, ya que existe una gran dispersión en las edades. En el caso de Loja, esto implica que la población extranjera no se concentra en un rango específico, por lo

que el promedio puede resultar poco representativo y debe complementarse con otras medidas estadísticas.

- **Revise el parámetro ddof de la función var() en Pandas. ¿Qué ocurre con el estimador de la varianza si establecemos ddof=0 y en qué escenario específico de población poblacional esto sería matemáticamente correcto?**

Al establecer ddof=0, el estimador de la varianza cambia su divisor de $N-1$ a N , eliminando la corrección de Bessel para calcular directamente la varianza poblacional, lo cual genera un estimador sesgado que tiende a subestimar la dispersión si se aplica a una simple muestra; sin embargo, este ajuste es el enfoque matemáticamente correcto de forma exclusiva en el escenario específico donde el conjunto de datos contiene a la población completa e íntegra (el 100% de los elementos de interés que deseas analizar) y no se busca utilizar esos datos para hacer inferencias sobre un grupo general más grande

- **Observe el histograma generado en la Tarea 3. ¿De qué manera el cálculo combinado de la esperanza matemática (media) y la varianza se apoyan en la identificación estadística de valores atípicos (outliers) para la posterior limpieza de su Proyecto Integrador?**

La combinación de la esperanza matemática y la varianza permite establecer un umbral de normalidad mediante el cálculo de la desviación estándar. Al identificar qué tan lejos se encuentran los datos del promedio (la línea roja de tu gráfico), puedes detectar matemáticamente los valores atípicos: aquellos rangos de edad con poblaciones extremadamente altas o bajas que se alejan significativamente de la media y que podrían sesgar los resultados finales.



En la fase de limpieza de tu proyecto, estos estadísticos sirven para justificar la exclusión o agrupación de datos erráticos o irrelevantes. Por ejemplo, te permiten decidir si los valores mínimos de edades avanzadas deben eliminarse por su alta variabilidad, asegurando así que el modelo estadístico resultante sea más preciso, robusto y representativo del comportamiento general de la población estudiada.

8. Rúbrica de Evaluación

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
1. Evaluación Clase Invertida (Semana 4)	2.0 puntos	Ejecución exitosa del script de la V.A. modificado (demostración en pantalla de PMF/PDF).
2. Momentos con Scipy	2.0 puntos	Bloque de código de la Tarea 2 funcional, sin errores de sintaxis y mostrando $E[X]$ y $V[X]$ exactos.
3. Hito: Análisis de Tendencia Central	3.0 puntos	Cálculo correcto de la media y varianza en el dataset regional propio, acompañado de visualización (histograma con línea de media).
4. Justificación ABI (Parámetro ddof)	1.5 puntos	Párrafo escrito en el notebook explicando el concepto de <i>grados de libertad</i> y el <i>estimador insesgado</i> .
5. Preguntas de Control	1.5 puntos	Respuestas redactadas en el Notebook (sección final) demostrando análisis crítico, uso de notación matemática y comprensión del negocio/región.
Total	10.0 puntos	

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.



unl

Universidad
Nacional
de Loja

-
- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

**Elaborado
por**

Cristian R. Narváez Guillén
Docente

**Aprobado
por**

Edison L Coronel Romero
Director de Carrera

11. Anexos

Enlace al google colab:

<https://colab.research.google.com/drive/1LvHyhhQhwxvyoFOggmG-L7yDAzVZh3TO?usp=sharing>

Declaración de uso de la IA:

Se usó Gemini para la implementación de correcciones en código y estructura del documento, consulta de errores en tablas y adaptación de síntesis.