

Guía de Actividades Práctico-Experimentales Nro. 006

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	1
Resultado de aprendizaje de la unidad	Calcula probabilidades y momentos de variables aleatorias discretas, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	006
Título de la Práctica	Distribuciones Discretas Notables: Modelado y Simulación de Procesos de Bernoulli y Eventos Raros
Nombre del Docente	Cristian Ramiro Narváez Guillén
Nombre del Grupo	Grupo A
Integrantes	Elvis Guayas Carlos Martinez Erick Rogel Isaac Vire Mateo Yanangomez
Fecha	Martes 12 de mayo del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Modelar** fenómenos estocásticos discretos calculando la Función de Masa de Probabilidad (PMF) y la Función de Distribución Acumulada (CDF) utilizando el módulo `scipy.stats` en Python.
- **Aplicar** el modelo de distribución de Poisson para analizar variables de conteo (eventos por unidad de tiempo/espacio) dentro del conjunto de datos regional del Proyecto Integrador (ABP).

- **Investigar** y demostrar computacionalmente el teorema del límite que rige la aproximación de la distribución Binomial a la distribución de Poisson (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Enfoque PID-2025:

- ABP (Aprendizaje Basado en Problemas): El estudiante debe identificar qué variables de su propio dataset regional cumplen con los supuestos de las distribuciones discretas (conteo, independencia) y justificar el ajuste de estos modelos teóricos a datos empíricos reales.
- ABI (Aprendizaje Basado en Investigación): Indagación matemática sobre los límites asintóticos ($n \rightarrow \infty, p \rightarrow 0$) que permiten la convergencia entre distribuciones de probabilidad.
- Duración sugerida: 120 min. (presencial).
- Modalidad: Grupos de trabajo (para contextualización del proyecto) con programación e informe técnico individual.

Tarea 1: Modelado Computacional de la Distribución Binomial

La distribución Binomial modela el número de éxitos x en n ensayos independientes de Bernoulli, con probabilidad de éxito p . Su PMF está dada por:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$$

Abra un nuevo Jupyter Notebook llamado APE_006_Distribuciones.ipynb.

Suponga un escenario de control de calidad de software donde un lote de 20 microservicios tiene una probabilidad del 15% de fallar bajo estrés. Escriba y ejecute el siguiente código:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom

# Parámetros del modelo Binomial
n_ensayos = 20
p_falla = 0.15

# Dominio de la variable aleatoria (0 a n)
x = np.arange(0, n_ensayos + 1)

# Cálculo de PMF (Función de Masa) y CDF (Función Acumulada)
pmf_binomial = binom.pmf(x, n_ensayos, p_falla)
cdf_binomial = binom.cdf(x, n_ensayos, p_falla)

# Visualización
fig, ax = plt.subplots(1, 2, figsize=(14, 5))

# Gráfico PMF
ax[0].vlines(x, 0, pmf_binomial, colors='b', lw=5, alpha=0.5)
ax[0].plot(x, pmf_binomial, 'bo', ms=8)
ax[0].set_title(f'PMF - Binomial (n={n_ensayos}, p={p_falla})')
ax[0].set_xlabel('Número de fallos (x)')
ax[0].set_ylabel('P(X = x)')
ax[0].grid(True, alpha=0.3)

# Gráfico CDF
ax[1].step(x, cdf_binomial, where='post', color='r', lw=2)
```

```
ax[1].plot(x, cdf_binomial, 'ro', alpha=0.5)
ax[1].set_title('CDF - Distribución Acumulada')
ax[1].set_xlabel('Número de fallos (x)')
ax[1].set_ylabel('P(X <= x)')
ax[1].grid(True, alpha=0.3)
```

```
plt.tight_layout()
plt.show()
```

```
# Cálculo de probabilidad específica: P(X <= 3)
prob_max_3 = binom.cdf(3, n_ensayos, p_falla)
print(f"La probabilidad de tener 3 fallos o menos es: {prob_max_3:.4f}")
```

Tarea 2: Modelado de la Distribución de Poisson (Eventos Raros)

La distribución de Poisson modela el número de eventos que ocurren en un intervalo de tiempo o espacio continuo, con una tasa media conocida λ . Su PMF es:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$


Suponga que los servidores de la universidad en Loja reciben en promedio $\lambda = 4.5$ peticiones de acceso erróneas por minuto.

Basándose en la estructura del código de la Tarea 1, implemente la simulación utilizando `scipy.stats.poisson`. Grafique únicamente la PMF evaluando desde $x = 0$ hasta $x = 15$.

Calcule mediante código la probabilidad exacta de recibir exactamente 6 peticiones erróneas en un minuto: $P(X = \quad)$.

Resultados de la actividad:

Distribución de Poisson graficada



La probabilidad exacta de recibir exactamente 6 peticiones es: 0.1281

Tarea 3: Hito del Proyecto - Identificación de Variables de Conteo (ABP)


Cargue su dataset regional en pandas.

Identifique una variable discreta que representa un "conteo" (ej. número de accidentes semanales en Loja, número de transacciones diarias, cantidad de clientes por hora).

Calcule la media muestral ($\bar{x}$) de esa variable y asuma que es el parámetro λ para un modelo de Poisson teórico.

Genere un gráfico superponiendo el histograma de densidad de su variable empírica contra la línea de la PMF teórica de Poisson generada en scipy. Discuta visualmente si los datos reales siguen esta distribución.

Resultados de la actividad:



Los gráficos muestran que la realidad no sigue la teoría, dado que los datos dentro de los dos datasets, si bien son de conteo, estos siguen una alta variabilidad y fluctuación entre periodos de tiempo, dado por fenómenos que elevan o bajan drásticamente las mediciones, evitando que sean constantes, algo importante para trabajar con Poisson.

Tarea 4: ABI - Aproximación Binomial a Poisson

Resultados de la actividad:

Investigue bajo qué condiciones matemáticas una distribución Binomial se aproxima a una de Poisson.

Condiciones en las que una distribución binomial se aproxima a una poisson

Las condiciones tienen que ser muy "raras" para que esto se cumpla, teniendo en cuenta que n (el número de iteraciones) tiene que tender al infinito o poniéndolo en un valor específico sería $n \geq 100$ iteraciones, la probabilidad debe ser muy pequeña o tender a 0 si usamos un dato matemático sería $P \leq 0.05$ también puede ser un valor más alto o máximo de $P \leq 0.1$.

La variable de P tiene que aumentar en proporción del incremento de n , si la variable P no cambia mientras n incrementa entonces se aproxima más a una distribución normal y no a la distribución Poisson.


Redacte un bloque Markdown explicando la relación $\lambda = n \cdot p$ cuando $n \rightarrow \infty$ y $p \rightarrow 0$.

Relación de $\lambda = np$ cuando $n \rightarrow \infty$ y $p \rightarrow 0$:

Teniendo en cuenta que las variables tienden a valores muy lejanos uno de otro, cuando tenemos este caso no podemos contar un número específico de iteraciones o la probabilidad de éxito por cada caso, al tener las variables tomando valores tan extremos a lo que se recurre es a usar una constante en este caso λ , la fórmula quedaría $\lambda = n \cdot p$ donde esto permite un equilibrio y hace que los valores tan caóticos se vuelvan predecibles para un análisis, puesto que mantiene el "promedio" y el flujo en movimiento de los datos de n y p haciendo que p disminuya al mismo ritmo que n aumenta.

Escriba un pequeño script en Python que calcule $P(X = \text{valor})$ usando un modelo Binomial con $n = 1000$ y $p = 0.003$, y compare el resultado imprimiendo también el valor de $P(X = \text{valor})$ en un modelo de Poisson donde $\lambda = 1000 \cdot 0.003 = 3$. Demuestra que los valores son casi idénticos.

Script creado



```
Probabilidad Binomial en x=3: 0.224379
Probabilidad Poisson en x=3: 0.224042
Diferencia: 0.00033676
```

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (itertools).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- **Matemáticamente y conceptualmente, ¿por qué la Función de Distribución Acumulada (CDF) de una variable aleatoria discreta tiene una gráfica en forma de "escalera" (step function) a diferencia de las funciones continuas?**

La razón por la que la Función de Distribución Acumulada (CDF) de una variable aleatoria discreta tiene forma de "escalera" se reduce a cómo se comporta la probabilidad cuando los posibles resultados están separados y aislados entre sí.

- **Analizando los supuestos del experimento de Bernoulli, si extraemos cartas de una baraja sin reemplazo buscando ases, ¿podemos modelar este escenario con una distribución Binomial? Justifique estadísticamente su respuesta.**

La respuesta sería que no. Estocástica y conceptualmente, extraer cartas sin reemplazo rompe las condiciones fundamentales necesarias para utilizar una distribución Binomial.

Para entender exactamente por qué el modelo colapsa en este escenario, debemos someter el proceso a los cuatro supuestos inquebrantables de un experimento de Bernoulli y, por extensión, de la distribución Binomial.

- **En la Tarea 3 de su proyecto (ABP), ¿qué limitaciones existen al asumir que la tasa media (λ) calculada de su dataset permanece constante a lo largo de todo el periodo de estudio? ¿Se cumple la propiedad de estacionariedad?**

Las limitaciones que se presentan radican en que al ser λ considerada como una constante, limita la capacidad para realmente entender e interpretar los datos que da el dataset, pues los accidentes y causas no permanecen constantes a través del tiempo y con la misma proporción. Dando paso a una mala descripción de la realidad. Y, por lo tanto, tampoco se cumple la propiedad de estacionalidad, pues la

media y varianza del dataset tampoco son permanentes, sino que fluctúan entre años y meses.

- A partir de la investigación en la Tarea 4 (ABI), ¿cuáles son los umbrales prácticos (valores comúnmente aceptados en la literatura estadística de n y p) para considerar que la aproximación de Poisson a la Binomial es segura y válida?

Para n serían los valores de números de interacción estos deben ser números grandes que tiendan al infinito y para p probabilidad de evento debe ser una probabilidad muy pequeña o que tiendan a cero.

Para que esta aproximación a Poisson se mantenga, la probabilidad p está vinculada al incremento de n . Si p se mantiene como un valor constante que no cambia mientras n incrementa, entonces la gráfica deja de aproximarse a Poisson y pasa a aproximarse a una **distribución Normal**.

- Si $X \sim \text{Poisson}(\lambda)$, sabemos teóricamente que $E[X] = \lambda$ y $V[X] = \lambda$. ¿Se cumple esta propiedad (media igual a varianza) en la variable de conteo que extraí de su dataset regional? Calcule ambos estadísticos muestrales y comente.

```
... --- ANÁLISIS DE PROPIEDADES DE POISSON ---

Dataset Accidentes:
- Media Muestral: 32.54
- Varianza Muestral: 333.28

Dataset Causas:
- Media Muestral: 8.32
- Varianza Muestral: 297.58
```

No, ya que por la estacionalidad y alta fluctuación de datos entre un periodo de tiempo a otro, es que el uso de Poisson, en donde se asume una tasa de eventos constantes, no es ideal para la descripción de los datos obtenidos. Ambos estadísticos muestrales varían bastante.

8. Rúbrica de Evaluación



Criterio Evaluado (Puntaje Máximo)	Nivel 3: Excelente (100%)	Nivel 2: Satisfactorio (50% - 75%)	Nivel 1: Insuficiente (0% - 49%)
1. Modelado Binomial y Poisson (2.5 pts)	Tareas 1 y 2 correctas: código funcional, incluye gráficas PMF/CDF y cálculo de probabilidad exacto.	Tareas completadas con errores menores en código/gráficos o un error en el cálculo de probabilidad.	Tarea incompleta o código no funcional. No hay gráficos ni cálculos.
2. Aplicación Proyecto (ABP) (3.0 pts)	Tarea 3 completa: identifica y justifica la variable de conteo, calcula λ empírico, y genera la superposición Histogram-PMF con análisis.	Tarea completada, pero con λ incorrecto o fallos de formato/visualización en el gráfico de superposición.	Tarea 3 no realizada o variable seleccionada no es de conteo discreta.
3. Demostración asintótica (ABI) (1.5 pts)	Tarea 4 correcta: explicación teórica de la relación $n \rightarrow \infty$ y $p \rightarrow 0$, y script Python que demuestra la convergencia.	Bloque Markdown ambiguo/incompleto, o script que no demuestra claramente la aproximación.	Tarea 4 no realizada (código y explicación teórica ausentes).
4. Preguntas de Control (2.0 pts)	Responde las 5 preguntas de manera clara, fundamentada y con notación estadística correcta.	Responde 3 o 4 preguntas. Las justificaciones son superficiales o con errores menores en notación.	Responde 2 preguntas o menos. Las respuestas son incorrectas o sin fundamento teórico.
5. Organización y Estilo de Código (1.0 pts)	Notebook profesional con estructura lógica, celdas Markdown legibles y comentarios pertinentes.	Formato inconsistente o falta de comentarios clave. Estructura aceptable.	Código ilegible o sin comentar. No utiliza celdas Markdown o la estructura es desordenada.

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.



[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3rd ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	

11. Anexos

Enlace al google colab:

https://colab.research.google.com/drive/18a7SNUd3k4dVnDJOz_S1rfCC0S3IITVF?usp=sharing