

Guía de Actividades Práctico-Experimentales Nro. 006

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	006
Título de la Práctica	Distribuciones Continuas Notables: Modelado Gaussiano, Estandarización y Pruebas de Normalidad
Nombre del Docente	Cristian Ramiro Narváez Guillén
Nombre del Grupo	Grupo A
Integrantes	Elvis Guayas Carlos Martinez Erick Rogel Isaac Vire Mateo Yanangomez
Fecha	Martes 19 de mayo del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- Modelar computacionalmente la Función de Densidad de Probabilidad (PDF) y la Función de Distribución Acumulada (CDF) de la distribución Normal utilizando scipy.stats.

- Aplicar el proceso de estandarización (Z -scores) sobre variables continuas del dataset regional del Proyecto Integrador, calculando la probabilidad de ocurrencia de eventos específicos (ABP).
- Investigar y ejecutar métodos visuales (Gráficos Q-Q) y analíticos (Test de Shapiro-Wilk) para validar matemáticamente el supuesto de normalidad en datos empíricos (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante asumirá que una variable continua crítica de su proyecto (ej. temperatura, salario, velocidad de red) sigue una distribución Normal y deberá resolver un problema probabilístico real calculando el área bajo la curva.
- **ABI (Aprendizaje Basado en Investigación):** Indagación sobre cómo demostrar científicamente si un conjunto de datos *realmente* proviene de una distribución Gaussiana, superando la simple inspección visual del histograma.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con discusión de resultados en los grupos del Proyecto Integrador.

Tarea 1: Modelado Matemático y Visualización de la Curva Normal

La Función de Densidad de Probabilidad (PDF) de una variable aleatoria continua $X \sim N(\mu, \sigma^2)$ se define como:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

1.

Abra un nuevo Jupyter Notebook llamado APE_007_Normal.ipynb.

2. Suponga que el tiempo de respuesta de un servidor local se distribuye normalmente con una media de $\mu = 120$ ms y una desviación estándar de $\sigma = 15$ ms. Escriba el siguiente código para graficar la distribución y sombrear el área que representa $P(X \leq 100)$, es decir, respuestas ultrarrápidas.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm

# Parámetros poblacionales
mu = 120
sigma = 15

# Definición del dominio (eje X): usualmente de mu-4sigma a mu+4sigma
x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)

# Cálculo de la PDF teórica
pdf_normal = norm.pdf(x, loc=mu, scale=sigma)

# Configuración del gráfico
plt.figure(figsize=(10, 5))
plt.plot(x, pdf_normal, 'b-', lw=2, label=f'N({mu}, {sigma}^2)')

# Sombreado del área de interés: P(X <= 100)
x_fill = np.linspace(mu - 4*sigma, 100)
y_fill = norm.pdf(x_fill, loc=mu, scale=sigma)
```

```
plt.fill_between(x_fill, y_fill, color='red', alpha=0.3, label='P(X ≤ 100)')
```

```
plt.title('Función de Densidad de Probabilidad - Distribución Normal')
plt.xlabel('Tiempo de Respuesta (ms)')
plt.ylabel('Densidad f(x)')
plt.axvline(mu, color='k', linestyle='--', label='Media (μ)')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```


Cálculo analítico de la probabilidad usando CDF

```
prob_100 = norm.cdf(100, loc=mu, scale=sigma)
```

```
print(f"La probabilidad de que el servidor responda en 100ms o menos es:
```

```
{prob_100:.4f} ({prob_100*100:.2f}%)")
```

Resultados obtenidos por el grupo:



Tarea 2: Estandarización y Cálculo de Valores Z

La estandarización permite transformar cualquier variable $X \sim N(\mu, \sigma^2)$ a una Normal Estándar $Z \sim N(0, 1)$ mediante:

$$Z = \frac{X - \mu}{\sigma}$$

1.

En una nueva celda, calcule manualmente (usando Python básico) el valor Z para $X = 145$ ms (tiempo de respuesta lento).

2. Utilice `norm.cdf(Z, loc=0, scale=1)` para encontrar $P(X \geq 145)$. Pista: Recuerde que la CDF calcula el área a la izquierda, por lo que para buscar mayor o igual debe usar $1 - P(Z)$.

Resultados obtenidos por el grupo:

```
El valor Z para X = 145 ms es: 1.6667
La probabilidad de que X sea mayor o igual a 145 ms es: 0.0478 (4.78%)
```

Tarea 3: Hito del Proyecto - Aplicación Probabilística Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Seleccione una variable de naturaleza continua (ej. precipitación milimétrica, altitud, consumo eléctrico).
3. Extraiga la media muestral ($\bar{x}$) y la desviación estándar muestral ($\bar{s}$). Para este ejercicio, asume que estos estadísticos son estimadores perfectos de μ y σ .
4. Defina un escenario problemático ("¿Cuál es la probabilidad de que la variable caiga en un rango crítico $[a, b]$ en la región?").
5. Calcule dicha probabilidad utilizando `scipy.stats.norm.cdf(b) - scipy.stats.norm.cdf(a)` usando los parámetros empíricos. Imprima el resultado y su interpretación para el negocio/proyecto.

Resultados obtenidos por el grupo:

```
--- Análisis de Probabilidad Corregido ---
Registros procesados: 29131
Parámetros:  $\mu = 42.6439$ ,  $\sigma = 240.8388$ 
Escenario: Probabilidad de precio en rango [0.5 - 1.5] USD
Resultado: 0.1632%
```



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de Computación

El resultado muestra que hay una baja probabilidad de que los precios caigan bajo ese rango definido, acompañado de la variación y media, podemos darnos cuenta de que es muy alta, por lo que los valores están muy dispersos entre sí. Por otra parte, podemos saber con más claridad la probabilidad de que el precio de una acción esté fuera del rango esperado.

Tarea 4: ABI - Validación Matemática del Supuesto de Normalidad

En la Tarea 3, usted *asumió* que la variable regional era Normal. En la estadística rigurosa, esto debe probarse. Investigue y ejecute lo siguiente:

1. **Método Gráfico:** Generar un Gráfico Cuantil-Cuantil (Q-Q Plot) utilizando la librería statsmodels.api. Si los puntos siguen la línea diagonal de 45 grados, los datos son aproximadamente normales.
2. **Método Analítico:** Ejecutar el test de Shapiro-Wilk (scipy.stats.shapiro).

```
import statsmodels.api as sm
```

```
from scipy.stats import shapiro
```

```
# Asuma que 'datos_variable' es el array extraído de su dataset en la Tarea 3
```

```
# datos_variable = df_regional['SuVariableContinua'].dropna()
```

```
# 1. Gráfico Q-Q
```

```
# sm.qqplot(datos_variable, line='s')
```

```
# plt.title('Gráfico Q-Q de Normalidad')
```

```
# plt.show()
```

```
# 2. Test de Shapiro-Wilk
```


```
# stat, p_value = shapiro(datos_variable)
```

```
# print(f"Estadístico de Shapiro: {stat:.4f}, p-valor: {p_value:.4e}")
```

Resultados obtenidos por el grupo:

... Análisis basado en una muestra aleatoria de 5000 registros.

<Figure size 800x600 with 0 Axes>



--- Resultados de la Prueba en la Muestra ---
Estadístico de Shapiro: 0.1646
p-valor: 1.2189e-91

CONCLUSIÓN: Con n=5000, se RECHAZA la normalidad.

Los valores obtenidos no presentan una distribución normal, pues están muy dispersos dentro del dataset, debido a que hay valores de las transacciones efectuadas muy altos que rompen la simetría

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (itertools).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- Matemáticamente, ¿por qué en una variable aleatoria continua modelada por una función de densidad $f(x)$, la probabilidad de que tome un valor exacto es cero, es decir, $P(X = c) = 0$?

Porque el valor requerido es infinito cuando se trata de variables continuas y no puede dar un dato fijo matemáticamente, por eso se tiene que usar puntos o intervalos dentro de ese amplio rango de posibles resultados.

- Interprete conceptualmente qué significa que un valor de su dataset regional tenga un puntaje estándar de $Z = -2.45$. ¿Se consideraría un valor atípico bajo el criterio de la regla empírica?

Sí, bajo el criterio general de la regla empírica se considera un valor inusual o atípico, ya que supera las 2 desviaciones estándar por debajo de la media ($|-2.45| > 2$), ubicándose en una zona donde se encuentra un porcentaje muy pequeño y extremo de la población

¿Es un valor atípico (outlier) según la Regla Empírica?

La **Regla Empírica** se aplica a distribuciones con forma de campana (normales) y establece lo siguiente:

- **68%** de los datos están a ± 1 desviación estándar de la media.
- **95%** de los datos están a ± 2 desviaciones estándar de la media.
- **99.7%** de los datos están a ± 3 desviaciones estándar de la media.

Bajo el criterio estándar de la regla empírica, un valor se suele considerar **atípico** si está más allá de ± 2 o ± 3 desviaciones estándar (dependiendo de qué tan estricto sea el análisis).

Como $|-2.45| > 2$, el valor está fuera del 95% central de los datos. Sin embargo, todavía está dentro del rango de las 3 desviaciones estándar (que cubre el 99.7%).

Si usamos el criterio común de $Z > |2|$, entonces **sí se considera un valor atípico**. Es un valor inusual que sólo superaría (hacia la izquierda) a menos del 1% de la población total si la distribución es normal.

- En la Tarea 3, calculó probabilidades asumiendo que su variable regional seguía una distribución Normal. ¿Qué riesgo metodológico existe al tomar decisiones basadas en este cálculo si la gráfica de la variable presenta un fuerte sesgo (skewness)?

El hecho de que una variable presente un fuerte sesgo, permite que las acciones tomadas en base a ese modelo sean erradas, al momento de analizar los datos, se obtendrá un conocimiento erróneo y se procederá a tomar acciones con expectativas que nunca se cumplan o se construyan modelos que fallarán al representar la realidad.

- Con base en la Tarea 4 (ABI), si el p-valor del test de Shapiro-Wilk es 0.001, ¿cuál es la conclusión estadística respecto a la distribución de sus datos regionales? ¿Se invalida el cálculo realizado en la Tarea 3?

La conclusión sería que los datos no siguen una distribución normal y por lo tanto los datos son dispares. Y por lo tanto, se invalida el cálculo realizado en la tarea 3, pues da un modelo que muestra aproximaciones erróneas y es óptimo para poder tomar decisiones fundamentadas.

- Explique el principio matemático detrás del Gráfico Q-Q. ¿Qué representan los cuantiles teóricos en el eje X versus los cuantiles empíricos en el eje Y?

El **Gráfico Q-Q (Quantile-Quantile Plot)** es una herramienta gráfica diseñada para comparar dos distribuciones de probabilidad comparando sus cuantiles. Su principio matemático se basa en la idea de que, si dos variables aleatorias siguen la misma distribución, la relación entre sus cuantiles será lineal

El eje horizontal (**X**) representa los cuantiles de una **distribución teórica ideal**

- **Matemáticamente:** Se obtienen mediante la **función cuantil inversa** (F^{-1}) de la distribución que estamos probando.
- Si tenemos **n** puntos de datos, dividimos la probabilidad acumulada total (1) en **n+1** intervalos. Los cuantiles teóricos son los valores x tales que:

$$X_i = F^{-1}(i - 0.5/n)$$

El eje vertical (**Y**) representa los cuantiles de tus **datos observados** (la muestra real).

- **Matemáticamente:** Para obtener estos valores, simplemente tomamos la muestra y la **ordenamos de menor a mayor**.
- El primer dato ordenado es el cuantil empírico más bajo, el último es el más alto.

8. Rúbrica de Evaluación

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
1. Modelado Gaussiano Teórico	2.0 puntos	Ejecución de las Tareas 1 y 2, mostrando el gráfico con el área sombreada correcta y el cálculo preciso del Z-score.
2. Aplicación Regional (ABP)	3.0 puntos	Selección de variable continua del dataset propio, definición de



		rango $[a, b]$, y cálculo preciso de su probabilidad (CDF).
3. Pruebas de Normalidad (ABI)	2.0 puntos	Generación correcta del Gráfico Q-Q y ejecución del test de Shapiro-Wilk, incluyendo adaptación de código para la variable empírica.
4. Preguntas de Control	2.0 puntos	Respuestas teóricamente fundamentadas, redactadas en celdas Markdown demostrando lectura comprensiva y rigor matemático.
5. Organización y Estilo	1.0 puntos	Documento Jupyter sin errores de sintaxis (SyntaxError), advertencias controladas, y uso estético de matplotlib/seaborn.
Total	10.0 puntos	

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	

11. Anexos

Enlace al google colab:
<https://colab.research.google.com/drive/19RP60xObgaqwrakXVIWkPfnRHMy3JzMw?usp=sharing>