

Guía de Actividades Práctico-Experimentales Nro. 006

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	007
Título de la Práctica	Distribuciones Muestrales y Teorema del Límite Central (TLC) mediante Simulación Estocástica
Nombre del Docente	Cristian Ramiro Narváez Guillén
Nombre del Grupo	Grupo A
Integrantes	Elvis Guayas Carlos Martinez Erick Rogel Isaac Vire Mateo Yanangomez
Fecha	Martes 26 de mayo del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Demostrar** computacionalmente el Teorema del Límite Central (TLC) extrayendo múltiples muestras aleatorias de distribuciones poblacionales marcadamente asimétricas (no normales) mediante programación en Python.

- **Aplicar** técnicas de remuestreo (bootstrapping básico) sobre el conjunto de datos regional del Proyecto Integrador, observando el comportamiento de las medias de submuestras empíricas (ABP).
- **Investigar** el impacto del tamaño de la muestra (n) en la reducción del Error Estándar de la Media (SE), validando matemáticamente la ley de los grandes números (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante resolverá el desafío de aplicar modelos de inferencia sobre variables regionales que inicialmente no cumplen el supuesto de normalidad, apoyándose en el poder del TLC.
- **ABI (Aprendizaje Basado en Investigación):** Indagación empírica y visual sobre qué sucede matemáticamente con la varianza poblacional cuando es fraccionada por el tamaño de la muestra ($\sqrt{n}$).
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica de simulación individual, seguida de una plenaria grupal de los equipos del Proyecto Integrador.

Tarea 1: Generación de una Población Asimétrica (No Normal)

El Teorema del Límite Central establece que, dada una población con media μ y varianza finita σ^2 , la distribución de las medias muestrales $\bar{X}$ se aproxima a una distribución Normal $N(\mu, \frac{\sigma^2}{n})$ a medida que el tamaño de la muestra n aumenta.

1. Abra un nuevo Jupyter Notebook llamado APE_008_TLC.ipynb.
2. Simulemos el tiempo de permanencia de usuarios en un portal web (variable típicamente asimétrica positiva) utilizando una distribución Exponencial con $\lambda = 0.5$ (media poblacional $\mu = 2$).

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
# 1. Creación de la Población "Universo" (Altamente asimétrica)
```

```
np.random.seed(42)
```

```
poblacion_exponencial = np.random.exponential(scale=2.0, size=100000)
```

```
mu_pob = np.mean(poblacion_exponencial)
```

```
sigma_pob = np.std(poblacion_exponencial)
```

```
print(f"--- Parámetros Poblacionales Reales ---")
```

```
print(f"Media ( $\mu$ ): {mu_pob:.4f}")
```

```
print(f"Desviación Estándar ( $\sigma$ ): {sigma_pob:.4f}")
```

```
# Visualización de la Población Original
```

```
plt.figure(figsize=(8, 4))
```

```
sns.histplot(poblacion_exponencial, bins=50, kde=True, color='orange')
```

```
plt.title("Distribución Poblacional (Exponencial) - Claramente NO Normal")
```

```
plt.xlabel("Tiempo de Permanencia")
```


```
plt.ylabel("Frecuencia")
```

```
plt.axvline(mu_pob, color='red', linestyle='dashed', label=f'Media: {mu_pob:.2f}')
```

```
plt.legend()
```

```
plt.show()
```

Resultados obtenidos por el grupo:



Tarea 2: Simulación Estocástica del Teorema del Límite Central

1. Para demostrar el TLC, vamos a extraer $k = 1000$ muestras aleatorias de tamaño $n = 30$ de nuestra población asimétrica. Calcularemos la media de cada muestra y graficaremos la distribución de estas 1000 medias.

Parámetros de la simulación

tamaño_muestra = 30 # n

numero_muestras = 1000 # k

Array para almacenar las medias de cada muestra

medias_muestrales = []

Bucle de Monte Carlo simple

for _ in range(numero_muestras):

 # Extraer muestra aleatoria sin reemplazo

 muestra = np.random.choice(poblacion_exponencial,
size=tamaño_muestra, replace=False)

 # Calcular y guardar la media

 medias_muestrales.append(np.mean(muestra))

```
# Estadísticos de la Distribución Muestral
```

```
media_de_medias = np.mean(medias_muestrales)
```

```
error_estandar_empirico = np.std(medias_muestrales)
```

```
error_estandar_teorico = sigma_pob / np.sqrt(tamaño_muestra)
```

```
print(f"--- Estadísticos de las Medias Muestrales (n={tamaño_muestra}) ---")
```

```
print(f"Media de las Medias Muestrales ( $E[\bar{X}]$ ): {media_de_medias:.4f}")
```

```
print(f"Error Estándar Empírico ( $\sigma_{\bar{x}}$ ): {error_estandar_empirico:.4f}")
```

```
print(f"Error Estándar Teórico ( $\sigma/\sqrt{n}$ ): {error_estandar_teorico:.4f}")
```

```
# Visualización de la convergencia a la Normal
```

```
plt.figure(figsize=(8, 4))
```

```
sns.histplot(medias_muestrales, bins=30, kde=True, color='blue')
```

```
plt.title(f"Distribución de las Medias Muestrales (n={tamaño_muestra}) -  
¡Convergencia a la Normal!")
```

```
plt.xlabel("Valor de las Medias Muestrales")
```


```
plt.ylabel("Frecuencia")
```

```
plt.axvline(media_de_medias, color='red', linestyle='dashed', label=f' $E[\bar{X}]$ :  
{media_de_medias:.2f}')
```

```
plt.legend()
```

```
plt.show()
```

Resultados obtenidos por el grupo:




```
--- Estadísticos de las Medias Muestrales (n=30) ---  
Media de las Medias Muestrales ( $E[\bar{X}]$ ): 1.9923  
Error Estándar Empírico ( $\sigma_{\bar{x}}$ ): 0.3653  
Error Estándar Teórico ( $\sigma/\sqrt{n}$ ): 0.3626
```

Tarea 3: Hito del Proyecto - Aplicación de Remuestreo al Dataset Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Elija la variable continua analizada en la Semana 7 (que quizá probó no ser normal con el test de Shapiro-Wilk).
3. Adapte el bucle for de la Tarea 2 para extraer 500 muestras de tamaño $n = 40$ directamente de la columna de su DataFrame (utilice `df['variable'].sample(n=40, replace=True)`).
4. Grafique el histograma de las medias obtenidas de su dataset regional. Observe y redacte una justificación de cómo esto soluciona problemas de asimetría para futuras predicciones del proyecto.

Resultados obtenidos por el grupo:




Tarea 4: ABI - Análisis del Error Estándar y la Ley de los Grandes Números

El Error Estándar de la media se define como $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$.

1. Escriba un script que realice la simulación de la Tarea 2 pero iterando sobre una lista de diferentes tamaños de muestra: `tamanos_n = [5, 10, 30, 50, 100, 500]`.
2. Para cada n , guarde la desviación estándar de las medias resultantes (el error estándar empírico).
3. Genere un gráfico de líneas tipo *scatter plot* conectando los puntos donde el eje X sea el tamaño de la muestra (n) y el eje Y sea el Error Estándar ($\sigma_{\bar{x}}$).
4. Documente en formato Markdown la forma geométrica de la curva generada (decaimiento asintótico) y su implicación económica al momento de recolectar datos en ingeniería.

Resultados obtenidos por el grupo:



A medida que se aumenta el tamaño de la muestra se puede apreciar cómo la curva del gráfico empieza a decaer, se acerca a cero aunque nunca llega a él, esto por que los datos obtenidos nunca serán iguales, la desviación estándar no será cero. Esto significa que el error se reduce mientras más grande es una muestra, pero que llega un punto en el que es innecesario seguir haciéndolo pues nunca se eliminará por completo. Por lo tanto, se tendrían que gastar muchos recursos, entre ellos económicos, para lograr encoger el error lo más que se pueda, lo que no es viable económicamente porque de todas formas habrá un margen de error, por ende en este punto es mejor considerar cuál es el mínimo aceptable para el proyecto, en pro de ahorrar los recursos, en vez de tirarlos inútilmente. Se tiene que encontrar un equilibrio.

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (itertools).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- **Basado en la Tarea 1 y 2, ¿por qué el Teorema del Límite Central es considerado el puente matemático fundamental entre la probabilidad descriptiva y la inferencia estadística?**

El Teorema del Límite Central (TLC) es apodado el "puente" porque resuelve el problema más grande de la estadística: ¿Cómo se puede saber algo de una población entera si solo tengo una pequeña muestra?

En Probabilidad Descriptiva sólo se puede hablar de los datos que se tiene en la mano. Si la muestra no es "normal" (gaussiana), las herramientas son limitadas.

El Puente (TLC) establece que si se toman suficientes muestras, el promedio de esas muestras siempre formará una campana de Gauss, sin importar si los datos originales eran uniformes, exponenciales o totalmente caóticos.

El TLC "normaliza" la realidad. Gracias a él, podemos usar la distribución normal Z para casi todo. Por él se puede calcular el Error Estándar, que define cuánta variación esperar entre diferentes muestras. Sin él, no se podría calcular intervalos de confianza ni realizar pruebas de hipótesis, porque no habría una base matemática sólida para comparar los resultados

- **Demuestre con los resultados impresos en su consola de la Tarea 2, cómo se cumple la propiedad matemática fundamental de las distribuciones muestrales:** $E[\bar{X}] = \mu$.

La propiedad fundamental de las distribuciones muestrales dice que la media de la distribución muestral de las medias es igual a la media de la población, de donde vienen las muestras, dado que la media muestral es un estimador insesgado de la media poblacional. Al ejecutar el código, a medida que se vaya sacando la media de cada una de las muestras, por mucho que algunas varían, el proceso de promediar una gran cantidad de muestras, en este caso 1000, hace que el resultado se vuelva igual al del parámetro real de la población, la media poblacional, y junto a un tamaño mayor a 30, también se reduce el error estándar. Por último, pese a que la media poblacional se mantiene fija, la muestra varía en función de sus datos y su variabilidad,

dando casos en donde los datos están bastante dispersos, aquí se puede usar el teorema del límite central, siempre y cuando se tenga un tamaño de muestra ≥ 30 , para acercar la distribución de las medias muestrales a una distribución normal, más centrada en la media poblacional, ofreciendo un modelo preciso y seguro para obtener conclusiones válidas.

- **En la Tarea 4, al graficar la curva del Error Estándar frente a n , ¿por qué la curva no desciende de forma lineal? Si usted como ingeniero requiere reducir el error estándar a la mitad, ¿cuántas veces debe incrementar el tamaño de la muestra?**

No desciende de forma lineal porque n no es proporcional respecto al error estándar y, sumado a que el tamaño de las muestras varía bastante, da como resultado a que se presenten cortes abruptos al graficar la curva, misma que se estabiliza a medida que n crece, sin llegar a cero. Por otra parte, para reducir el error estándar a la mitad, dada la fórmula presentada, tendríamos que tener un tamaño de muestra cuatro veces más grande que el desvío estándar para poder reducirlo a la mitad, todo gracias a la raíz cuadrada de la fórmula.

- **Históricamente, en estadística clásica se establece la regla de oro de $n \geq 30$ para asumir normalidad. Si la población regional que usted analizó en la Tarea 3 tiene una asimetría extrema (ej. distribución de Pareto de riquezas), ¿es suficiente un $n = 30$ para que las medias muestrales se distribuyen normalmente? Justifique.**

Si la muestra tiene una asimetría extrema, el hecho de contar con n mayor a 30 no es suficiente como para que se cree una distribución normal, esto por la dispersión que tienen los datos, siendo necesario un mayor tamaño de la muestra para lograr la formación de una distribución normal, sin que los valores atípicos tengan tanto peso y creen un sesgo en la distribución de los datos.

- **Diferencie conceptual y operativamente los términos Desviación Estándar (σ) de una muestra individual y el Error Estándar de la Media ($\sigma_{\bar{x}}$) calculado en sus simulaciones.**

En lo que respecta a la desviación estándar, esta mide que tan alejados están los datos respecto a su propia media, así como ayudar a obtener el error estándar, pues la mayoría del tiempo se necesitará de la desviación estándar muestral al no tener la poblacional. Por otro lado, el error estándar mide que tan alejado está el promedio muestral de los datos respecto a su promedio poblacional. El primer concepto mide la variabilidad individual, el segundo la variabilidad del promedio de los datos respecto a la realidad. La forma de

operación de la desviación estándar viene dada por la fórmula:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}$$

En nuestro dataset, muestra que los datos analizados están muy dispersos, por los valores que se presentan, mucho con valores bajos frente a unos pocos con valores bastante elevados. Por otra parte, la forma de operación del error estándar viene dada por la fórmula:

$$\frac{\sigma}{\sqrt{n}}$$

Donde se cambia σ con s , si se desconoce la media poblacional. En nuestro dataset nos presenta que, si bien los datos están muy dispersos, a medida que tengamos un tamaño de muestra más grande, el promedio generado reduce cada vez más y más el error estándar, dándonos una información más confiable,

8. Rúbrica de Evaluación

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
1. Generación Poblacional (No Normal)	1.5 puntos	Ejecución de la Tarea 1, demostrando en gráfica la asimetría de la población base.
2. Simulación del TLC (Monte Carlo)	2.5 puntos	Bucle de simulación ejecutado correctamente (Tarea 2), con convergencia visible (gráfica de campana azul) y comparación teórica/empírica exacta.
3. Aplicación Regional (ABP)	2.5 puntos	Adaptación del código para operar sobre el DataFrame del



		Proyecto Integrador, mostrando remuestreo y normalidad resultante.
4. Análisis de Decaimiento del Error (ABI)	2.0 puntos	Bucle iterando sobre la lista tamanos_n y gráfico de decaimiento asintótico del error estándar correctamente generado.
5. Preguntas de Control	1.5 puntos	Respuestas teóricamente fundamentadas en Markdown, demostrando manejo técnico de conceptos (Error Estándar vs Desviación Estándar).
Total	10.0 puntos	

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



Universidad
Nacional
de Loja

10. Anexos

Enlace al google colab:
<https://colab.research.google.com/drive/1w5108HxDLax3pponcEYYIKOQIfzJvxq8?usp=sharing>



11. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	