



Reporte Técnico de Actividades Práctico-Experimentales Nro. 010

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	010
Título de la Práctica	Inferencia Estadística: Pruebas de Hipótesis Paramétricas (Z y T) y Análisis del Valor-p
Nombre del Docente	Cristian Ramiro Narváez Guillén
Nombre del Grupo	Grupo A
Integrantes	Elvis Guayllas Carlos Martinez Erick Rogel Isaac Vire Mateo Yanangomez
Fecha	Martes 9 de junio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas



2. Objetivo(s) de la Práctica

- **Formular** y ejecutar pruebas de hipótesis de una muestra para la media poblacional utilizando el estadístico (varianza conocida) y el estadístico (varianza desconocida) mediante Python.
- **Aplicar** el contraste de hipótesis al conjunto de datos regional del Proyecto Integrador, validando o refutando afirmaciones previas (o de literatura) sobre el comportamiento de la región (ABP).
- **Investigar** mediante simulación computacional la sensibilidad del valor frente al tamaño de la muestra (), diferenciando entre significancia estadística y significancia práctica (ABI).

3. Materiales, Reactivos, Equipos y Herramientas

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.xl
- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología Ejecutada

1.Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante asumirá el rol de un auditor de datos. Se enfrentará a una "afirmación oficial" sobre una métrica de su región (ej. "El tiempo medio de conexión es de 50ms") y usará sus datos empíricos para probar si hay evidencia suficiente para rechazar dicha afirmación.
- **ABI (Aprendizaje Basado en Investigación):** Indagación crítica sobre el peligro del *p-hacking* y cómo tamaños de muestra masivos pueden detectar diferencias minúsculas que son matemáticamente significativas, pero inútiles en la ingeniería práctica.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución individual con debate analítico grupal (Proyecto Integrador).

Tarea 1: Prueba de Hipótesis Z (Varianza Poblacional

Conocida / Muestra Grande)

Supongamos que el fabricante de unos microcontroladores afirma que el consumo de corriente en reposo es de $\mu_0 = 15$ mA. Usted toma una muestra de $n = 50$ chips y obtiene una media de $\bar{x} = 15.6$ mA. Por estudios previos, sabe que la desviación estándar poblacional es $\sigma = 1.2$ mA. ¿Miente el fabricante? Nivel de significancia $\alpha = 0.05$.

Hipótesis Nula (H_0): $\mu = 15$ mA

Hipótesis Alternativa (H_1): $\mu \neq 15$ mA (Prueba de dos colas)

Estadístico de prueba:

1.

$$Z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

Abra un nuevo Jupyter Notebook llamado APE_010_Hipotesis.ipynb.

2. Ejecute el siguiente código para calcular el estadístico Z y el

valor-*p* manualmente apoyándose en scipy.stats.norm:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm, ttest_1samp

# Parámetros del problema
mu_0 = 15.0
x_bar = 15.6
sigma = 1.2
n = 50
alpha = 0.05

# 1. Cálculo del estadístico Z de prueba
Z_calc = (x_bar - mu_0) / (sigma / np.sqrt(n))
```

2. Cálculo del valor-p (Prueba de dos colas)

sf (survival function) es 1 - cdf, calcula el área en la cola superior

p_value_z = 2 * norm.sf(np.abs(Z_calc))

```
print("--- Prueba de Hipótesis Z (Dos Colas) ---")
```

```
print(f"Estadístico Z calculado: {Z_calc:.4f}")
```

```
print(f"Valor-p: {p_value_z:.4e}")
```

```
if p_value_z < alpha:
```

```
    print("Conclusión: Se RECHAZA H0. Hay evidencia suficiente de que el  
    consumo medio NO es 15 mA.")
```

```
else:
```

```
    print("Conclusión: NO se rechaza H0. No hay evidencia suficiente para  
    refutar al fabricante.")
```

Tarea 2: Prueba de Hipótesis T (Varianza Desconocida / Muestra Pequeña)

En la práctica, σ casi nunca se conoce. Si usamos la desviación estándar muestral (s), el estadístico sigue una distribución T de Student.

Para esto, Python ofrece la abstracción `scipy.stats.ttest_1samp`.

1. Suponga un muestreo de tiempos de carga de una app (en segundos): [2.5, 3.1, 2.9, 3.8, 2.7, 3.3, 3.0, 2.8]. La

meta de la empresa (μ_0) es de 2.6 segundos.
¿Cumple la app la meta?

2. Implemente y analice este código:

```
# Muestra empírica pequeña (n=8)
```

```
tiempos_carga = [2.5, 3.1, 2.9, 3.8, 2.7, 3.3, 3.0, 2.8]
```

```
mu_meta = 2.6
```

```
alpha_t = 0.05
```

```
# Ejecución de la prueba T de una muestra (Prueba de una cola: H1: mu > 2.6)
```

```
# ttest_1samp devuelve p-value de 2 colas por defecto.
```

```
# Para cola superior (greater), p-value de 1 cola en SciPy moderno se especifica  
con alternative='greater'
```

```
stat_t, p_value_t = ttest_1samp(tiempos_carga, popmean=mu_meta,  
alternative='greater')
```

```
print(f"--- Prueba de Hipótesis T (Cola Superior) ---")
print(f"Estadístico T: {stat_t:.4f}")
print(f"Valor-p (1 cola): {p_value_t:.4f}")

if p_value_t < alpha_t:
    print("Se RECHAZA H0. Evidencia indica que el tiempo medio es MAYOR a 2.6s (Incumple la meta).")
else:
    print("NO se rechaza H0. El tiempo de carga estadísticamente cumple la meta.")
```

Tarea 3: Hito del Proyecto - Contraste en el Dataset Regional (ABP)

1. Importe su dataset regional.
2. Formule una afirmación razonable sobre la media de una variable cuantitativa (ej. "La temperatura media histórica en Loja es de 16°C" o "El salario promedio es de \$450"). Esta será su μ_0 .
3. Aplique `ttest_1samp` (Prueba T) sobre la columna de datos reales usando un nivel de significancia $\alpha = 0.05$. Defina claramente si usará una prueba de dos colas o de una cola (`alternative='two-sided', 'less', 'greater'`).
4. Redacte un párrafo interpretando el valor- p obtenido en términos de la problemática del negocio o la región.

Tarea 4: ABI - Significancia Estadística vs. Significancia

Práctica (Efecto del tamaño n)

¿Un valor- p pequeño siempre significa un descubrimiento revolucionario?

1. Genere una "población" en Python simulando un sensor con $\mu_{real} = 5.01$ V y $\sigma = 1.0$ V.
2. Nuestra Hipótesis Nula es $\mu_0 = 5.00$ V. Note que la diferencia real es apenas de 0.01V (probablemente irrelevante para la maquinaria).

3. Cree un bucle que extraiga muestras de esta población variando el tamaño: $n_list = [10, 100, 1000, 10000, 100000]$. En cada iteración, ejecute una prueba Z o T contra $\mu_0 = 5.00$ y guarde el valor- p .

4. Grafique $\bar{x}$ (Eje X, en escala logarítmica) vs. valor- p (Eje Y). Trace una línea horizontal roja en $\alpha = 0.05$.

5. Analice en formato Markdown: ¿Qué sucede con el valor- p cuando $\bar{x}$ crece masivamente, incluso si la diferencia real es insignificante?

Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:
Implementar pruebas de hipótesis paramétricas: Ejecutar correctamente pruebas Z y T en Python para la toma de decisiones estadísticas, seleccionando adecuadamente los parámetros según el conocimiento de la varianza poblacional.

Analizar datos empíricos del Proyecto Integrador: Validar o refutar hipótesis sobre parámetros poblacionales de la región de estudio, aplicando el enfoque de Aprendizaje Basado en Problemas (ABP).

Evaluar la sensibilidad estadística: Interpretar cómo el tamaño de la muestra afecta la significancia estadística (valor- p) mediante simulación computacional, distinguiendo entre relevancia estadística y relevancia práctica.

Comunicar hallazgos técnicos: Redactar conclusiones basadas en evidencia estadística, explicando los riesgos asociados a los errores Tipo I y Tipo II en contextos de ingeniería real.

Documentar procesos de análisis: Generar informes técnicos estructurados en Jupyter Notebook que integren código ejecutable, visualizaciones gráficas y justificaciones teóricas en formato Markdown y LaTeX.

5. Resultados Obtenidos Por el Grupo

Resultados de la Tarea 1

```
--- Prueba de Hipótesis Z (Dos Colas) ---  
Estadístico Z calculado: 3.5355  
Valor-p: 4.0695e-04  
Conclusión: Se RECHAZA  $H_0$ . Hay evidencia suficiente de que el consumo medio NO es 15 mA.
```

Resultados de la Tarea 2

```
*** --- Prueba de Hipótesis T (Cola Superior) ---
Estadístico T: 2.9055
Valor-p (1 cola): 0.0114
Se RECHAZA H0. Evidencia indica que el tiempo medio es MAYOR a 2.6s (Incumple la meta).
```


Resultados de la Tarea 3

Afirmación: El precio promedio histórico de las acciones en el mercado regional es de \$2.50 USD
 Parámetro: $\mu_0 = 2.50$
 Estadístico T: 28.4493
 Valor p: 0.0000

El valor -p es 0, esto por el hecho de que dentro del dataset, hay valores atípicos dentro de la variable "Precio". Esto genera que sea imposible decir que el precio promedio histórico en el mercado regional es de 2.50 USD. Revelando una alta segmentación y volatilidad de los precios que se manejan en el mercado. Por lo que no hay un precio promedio seguro que se pueda usar para tomar decisiones fiables.

Resultados de la Tarea 4

```
n = 10 --> Media = 4.69890 --> Z = -0.9522 --> p = 0.34101417
n = 100 --> Media = 5.00038 --> Z = 0.0038 --> p = 0.99693230
n = 1000 --> Media = 4.95142 --> Z = -1.5363 --> p = 0.12445647
n = 10000 --> Media = 5.01370 --> Z = 1.3702 --> p = 0.17062397
n = 100000 --> Media = 5.01121 --> Z = 3.5447 --> p = 0.00039312
```



Cuando n crece masivamente, el valor-p tiende a disminuir, incluso si la diferencia real entre la media observada y la hipótesis nula es muy pequeña o prácticamente irrelevante.

Esto ocurre porque al aumentar el tamaño de la muestra, el error estándar se reduce, haciendo que la prueba estadística sea capaz de detectar diferencias cada vez más pequeñas. Como consecuencia, una diferencia mínima, como 0.01 V, puede producir valores-p extremadamente bajos y llevar al rechazo de la hipótesis nula.

6. Preguntas de Control

- 1. ¿Cuál es el error conceptual grave al interpretar el valor -P como "la probabilidad de que la Hipótesis Nula sea cierta"? Defina correctamente el valor -P.

El valor $-p$ no mide la probabilidad de la hipótesis, sino la probabilidad de los datos y cómo estos desmienten o no a H_0 . Normalmente en estadística, la Hipótesis Nula (H_n) es fija, es decir no puede ser cierta o falsa, por lo que no tiene una probabilidad de ocurrir. La realidad es que el valor $-p$ es una probabilidad condicionada a que la hipótesis nula sea cierta, que no haya efecto.

El valor $-p$ es la probabilidad de obtener un resultado observado (o uno aún más extremo), asumiendo como premisa absoluta que la Hipótesis Nula (H_n) es verdadera.

En términos prácticos, es una medida de la compatibilidad entre los datos obtenidos y la hipótesis nula: un valor $-p$ muy bajo indica que los datos observados son extremadamente inusuales bajo el supuesto de que H_n sea cierta, lo que da motivos para rechazarla.

- **2. En el contexto de la Tarea 3 (Dataset Regional), describa en lenguaje no estadístico qué representaría cometer un Error Tipo I y un Error Tipo II en su toma de decisiones.**

Dar paso a un Error Tipo I significa que, se está asegurando que el precio promedio de acciones en el mercado es 2.50 USD y ha cambiado y, por lo tanto, hay que tomar decisiones diferentes a las que se venían tomando respecto al mercado. Pero eso es falso, y se toman acciones innecesariamente.

Por otro lado, un Error Tipo II significa que, se está asegurando que el precio promedio de acciones del mercado no ha cambiado. Por lo que se siguen tomando las mismas consideraciones que antes, cuando en realidad el mercado está cambiando y hace falta un nuevo análisis, para determinar si la situación es peligrosa para nosotros.

- **3. Si en su análisis regional la prueba arroja un $p = 0.051$ y su $\alpha = 0.05$, estadísticamente NO rechaza H_0 . Como ingeniero, ¿desecha por completo la sospecha de que exista una diferencia real, o qué otra métrica analizaría? (Pista: Relacione esto con la Semana 9).**

¿Se desecha?

No, técnicamente, no se debería rechazar la posibilidad de un cambio real, pero se deberían analizar otras métricas para validar si realmente hay diferencia o no. Pues tomar una decisión drástica basada solo en una milésima sería un gran error, ya que podría existir una diferencia real que la prueba no pudo confirmar debido a una muestra pequeña, por ejemplo.

¿Qué otra métrica utilizar?

Usamos el **Tamaño del Efecto**, ya que dice si el cambio que se detectó es grande o indiferente, permitiendo decidir si vale la pena invertir dinero o tiempo en esa sospecha regional.

También podría usarse el **IC**, para ver si el valor de H_0 está dentro de él, lo que impediría descartar la posibilidad de una diferencia real. O

por último, se podría **engrandecer la muestra** para verificar si el valor -p se estabiliza y muestra un resultado más claro.

- **4. Explique la conclusión de su investigación en la Tarea 4 (ABI). ¿Por qué en el "Big Data" las pruebas de hipótesis clásicas tienden a rechazar H_0 casi siempre?**

En el Big Data, al contar con un tamaño de muestras muy grande, se encoge el error estándar. Esto hace que, tanto en Z como en T, al dividir la diferencia observada entre este error estándar tan pequeño, se arroje un valor gigantesco y el -p sea cercano a 0. Esto ocurre porque, al ser el valor de Z o T tan grande, se tiende al infinito y se recorre prácticamente toda la función; por lo tanto, la probabilidad y el área bajo la curva de la cola se vuelven cero, ya que el valor-p es el residuo matemático, el de la cola, que falta para alcanzar el 100% de una función acumulada. Entonces, el sistema se vuelve tan sensible al ruido que cualquier mínima diferencia observada la toma en cuenta, aun si no es significativa, por lo que rechaza H_0 , incluso cuando esa diferencia insignificante no es algo de lo que preocuparse. Ningún H_0 es exacto, siempre habrá ruido, por lo que trabajar con Big Data genera un problema al considerar todo como significativo, ahí es donde entra el criterio del ingeniero para saber si lo que se muestra en la teoría es realmente necesario en la práctica.

- **5. Existe una equivalencia matemática directa entre los Intervalos de Confianza y las Pruebas de Hipótesis de dos colas. Si un IC del 95% para μ no incluye a μ_0 , ¿qué le sucederá inevitablemente al valor-p si evalúa $H_0 : \mu = \mu_0$ con $\alpha = 0.05$?**

Si el **Intervalo de Confianza (IC) del 95% no incluye el valor μ_0** , el **valor -p será menor a 0.05** ($p < 0.05$). El IC del 95% representa el conjunto de todos los valores de μ_0 para los cuales no se rechazaría la hipótesis nula. Si un valor queda fuera de este rango, automáticamente se rechaza H_0 . Un $\alpha = 0.05$ define el mismo umbral de error que un nivel de confianza del 95% ($1 - \alpha$). Si el valor nulo es tan distante de la estimación muestral que el intervalo no alcanza a incluirlo, entonces la probabilidad de obtener un resultado igual o más extremo (valor -P) es, por definición, menor al 5% de tolerancia.



7. Conclusiones

El uso de pruebas de hipótesis y del valor $-p$ permiten al ingeniero sacar conclusiones que puedan aclarar sus suposiciones previas, rechazando o no la hipótesis nula en base a la información obtenida. Esto permite que pueda decidir si la continuación de su proyecto debe tomar el rumbo ya establecido o realizar ajustes respecto a lo que estaba haciendo, o reconsiderar que el trabajo analizado cumple con los estándares esperados o si necesita un mayor desarrollo para lograr los resultados esperados.

8. Bibliografía / Referencias

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

9. Anexos

Enlace al Google Colab:
<https://colab.research.google.com/drive/15uT6kTjQwZIXI7ZiAk67GCQWjdW0wiTM?usp=sharing>